

BEYİN DALGASI (EEG) VERİLERİ KULLANILARAK SÜRÜCÜ UYKULULUK DURUMUNUN MAKİNE ÖĞRENMESİ YÖNTEMLERİ İLE SINIFLANDIRILMASI

Proje Ekibi: İbrahim Kışlak 1306240002 / Efe Kemal Çakmak 1306240098

Kurum: İstanbul Üniversitesi-Cerrahpaşa, Bilgisayar Mühendisliği Bölümü

Ders: Veri Bilimi / Final Projesi

Öğretim Üyesi: Dr. Öğr. Üyesi MUHAMMED ERDEM İSENKUL

1. GİRİŞ VE MOTİVASYON

1.1. Projenin Amacı ve Önemi

Ulaştırma sektöründe ve günlük trafikte sürücü yorgunluğu ile uykululuğu, ölümlü ve yaralanmalı kazaların en büyük nedenlerinden biridir. Geleneksel yöntemler genellikle araç şerit takibi veya kamera tabanlı yüz/göz izleme sistemlerine dayanmaktadır. Ancak bu sistemler, sürücü fiziksel olarak uyku belirtisi göstermeden hemen önceki "mikro-uyku" (micro-sleep) anlarını yakalamakta yetersiz kalabilir.

Bu projenin amacı, insan beyninin elektriksel aktivitesini doğrudan ölçen Elektroensefalografi (EEG) sinyallerini işleyerek, bir sürücünün uyanık mı yoksa uykulu mu olduğunu anlık olarak tespit eden yüksek doğruluklu bir ikili sınıflandırma (binary classification) modeli geliştirmektir.

1.2. Neden EEG ve Beyin Dalgaları?

EEG sinyalleri, merkezi sinir sisteminin durumunu doğrudan yansıttığı için bilişsel yorgunluğun tespitinde en güvenilir nesnel kaynaktır. Beynimiz gün içindeki aktivitelerine göre farklı frekans bantlarında dalgalar yayar:

- **Delta (δ):** Derin uyku evrelerinde baskındır.
- **Theta (θ):** Uykuya geçiş, yoğun yorgunluk ve mikro-uyku anlarında yükselir.
- **Alpha (α):** Gözler kapalı rahatlama ve sakinlik durumunda görülür.
- **Beta (β):** Aktif düşünme, odaklanma ve yüksek dikkat durumlarında baskındır.
- **Gamma (γ):** Yüksek düzeyde bilişsel işlem ve bilgi entegrasyonu sırasında açığa çıkar.

Modelimiz, bu dalgaların frekans ve genlik değişimlerindeki kalıpları öğrenerek can güvenliğini koruyacak bir erken uyarı sistemi algoritması oluşturmayı hedeflemektedir.

1.3. Gelecek Vizyonu ve Potansiyel Uygulamalar

Bu çalışmanın ilerleyen aşamalarında şu geliştirmeler hedeflenmektedir:

- **Real-Time (Gerçek Zamanlı) Entegrasyon:** Geliştirilen hafifletilmiş modelin, giyilebilir akıllı kasketler veya EEG bantları aracılığıyla sürücü esnasında canlı veri akışıyla çalıştırılması.
- **Edge AI (Uçta Yapay Zeka):** IoT cihazları ve araç içi gömülü sistemlere (Raspberry Pi, Nvidia Jetson vb.) entegre edilerek internet bağımsız çalışabilmesi.
- **Gelişmiş Akıllı Ulaşım Sistemleri (ITS):** Toplu taşıma (metrobüs, otobüs, tren) sürücülerinin anlık takibiyle hat güvenliğinin otonom merkezlerce izlenmesi.

2. VERİ SETİ TANIMI VE KEŞİFSEL VERİ ANALİZİ

2.1. Veri Kaynağı ve Yapısı

Projede kullanılan veri seti, Kaggle açık kaynak veri platformundan ("*sleepy-driver-eeeg-brainwave-data*") temin edilmiştir. Veri seti toplam **3735 satır** ve **11 sütundan** oluşmaktadır. Tüm bağımsız değişkenler ve hedef değişken sayısal veri tipindedir (**int64**). Veri setinde hiçbir **eksik değer** (**NaN/Null**) bulunmamaktadır.

2.2. Genişletilmiş EDA Bulguları

Veri setinin genel anatomisini anlamak adına gerçekleştirilen temel istatistiksel analizlerde şu çıktılar elde edilmiştir:

```
===== 1. VERİ SETİ BOYUTU (SHAPE) =====
Satır Sayısı: 3735 | Sütun Sayısı: 11
=====

===== 2. VERİ SETİ GENEL BİLGİSİ (INFO) =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3735 entries, 0 to 3734
Data columns (total 11 columns):
#   Column             Non-Null Count  Dtype  
---  --
0   attention            3735 non-null   int64   
1   meditation            3735 non-null   int64   
2   delta                3735 non-null   int64   
3   theta                3735 non-null   int64   
4   lowAlpha             3735 non-null   int64   
5   highAlpha            3735 non-null   int64   
6   lowBeta              3735 non-null   int64   
7   highBeta             3735 non-null   int64   
8   lowGamma             3735 non-null   int64   
9   highGamma            3735 non-null   int64   
10  classification        3735 non-null   int64   
dtypes: int64(11)
memory usage: 321.1 KB
=====

===== 3. RASTGELE ÖRNEKLEM (SAMPLE) =====
   attention  meditation  delta  theta  lowAlpha  highAlpha  lowBeta  \
3253         93          38  524519  365928   13222   23607   13222
3190         54          60  704691  123617   50572   47512   50572
2194         69          63  224642  216375    6599   13696    6599
3303         81          56  15859   27898    6882   13866    6882
642          20          35  351861  102722    5631   17346    5631

   highBeta  lowGamma  highGamma  classification
3253   152633    9665    477516              0
3190   20891     5928    306151              0
2194   34871   11287    526796              1
3303   7849   12082    77722              0
642    2865    1782     1625              1
=====
```

===== 5. TEMEL İSTATİSTİKLER (DESCRIBE) =====					
	count	mean	std	min	25% \
attention	3735.0	48.214726	21.876949	1.0	35.0
meditation	3735.0	56.577510	19.066577	1.0	43.0
delta	3735.0	518771.389290	599783.663336	216.0	71996.5
theta	3735.0	136242.001874	217550.078075	138.0	23472.0
lowAlpha	3735.0	33413.343775	51970.930842	32.0	7402.0
highAlpha	3735.0	30580.759036	52681.858764	9.0	6908.5
lowBeta	3735.0	25640.069076	37159.039642	2.0	6240.0
highBeta	3735.0	23276.979384	43921.116122	3.0	4862.0
lowGamma	3735.0	8117.130388	15522.904383	6.0	2247.0
highGamma	3735.0	208725.809906	329707.322778	47.0	5683.0
classification	3735.0	0.428380	0.494910	0.0	0.0

	50%	75%	max
attention	48.0	63.0	100.0
meditation	56.0	69.0	100.0
delta	277382.0	778068.0	3598743.0
theta	57972.0	151485.5	3194358.0
lowAlpha	16481.0	37721.5	699008.0
highAlpha	14928.0	33147.5	785947.0
lowBeta	13841.0	30236.0	595549.0
highBeta	9739.0	20796.5	443589.0
lowGamma	4440.0	8813.0	289281.0
highGamma	57198.0	257687.5	2328370.0
classification	0.0	1.0	1.0

Temel İstatistiksel Çıkarımlar:

- **Sınıf Dengesi (Class Balance):** Hedef değişkenimiz olan `classification` sütununda, verilerin **%57.16'sı Uyanık (0)**, **%42.84'ü ise Uykulu (1)** sürücülere aittir. Bu dağılım, veri setinin dengeli (balanced) olduğunu ve model eğitiminde veri çoğaltma (SMOTE vb.) veya yapay dengeleme işlemlerine ihtiyaç duyulmadığını kanıtlamaktadır. Geliştirilecek modellerin Accuracy (Doğruluk) metrikleri bu sayede güvenilirdir.
- **Veri Çarpıklığı (Skewness):** `describe()` çıktısı incelendiğinde, `delta` dalgasının medyan (%50) değeri 277,382 iken maksimum değerinin 3,598,743'e ulaştığı görülmüştür. Benzer şekilde `theta` dalgasının medyanı 57,972 iken maksimumu 3,194,358'dir. Standart sapmaların ortalamalardan çok daha yüksek olması, veride **sağa doğru belirgin bir çarpıklık (right-skewed)** ve yüksek uç değerler (outliers) olduğunu ortaya koymaktadır.
- **Çoklu Doğrusallık (Multicollinearity) ve Cihaz Hatası Sinyali:** Rastgele örneklem (`sample`) çıktısı detaylı incelendiğinde, `lowAlpha` ve `lowBeta` sütunlarının neredeyse tüm satırlarda **birebir aynı değerleri** aldığı fark edilmiştir. Bu durum, veri toplama cihazının donanımsal yapısından veya metrik üretim algoritmasından kaynaklanan bir tekrardır ve model mimarisinde boyut indirgemenin önemini göstermektedir.

```
===== 6. HEDEF DEĞİŞKEN DAĞILIMI (CLASS BALANCE) =====
Sayısal Dağılım:
classification
0    2135
1    1600
Name: count, dtype: int64

Yüzdesel Oran (Normalize):
classification
0    57.161981
1    42.838019
Name: proportion, dtype: float64
=====
```


Yukarıdaki çıktı incelendiğinde, veri setinde yer alan bağımlı hedef değişkenin (**classification**) sınıfsal dağılımının **%57.16 Uyanık (0)** ve **%42.84 Uykulu (1)** şeklinde olduğu görülmektedir. Veri bilimi literatüründe bu dağılım oranı, veri setinin **dengeli (balanced dataset)** bir yapıda olduğunu matematiksel olarak ispatlar.

Bu durumun projenin makine öğrenmesi safhası için kritik önemi şu şekildedir:

- **Doğruluk Paradoksunun (Accuracy Paradox) Önlenmesi:** Eğer veri setinde sınıflardan biri aşırı baskın olsaydı (örneğin %90 uyanık, %10 uykulu), model hiçbir şey öğrenmeden sadece sürekli "uyanık" tahmini yaparak %90 doğruluk (Accuracy) oranına ulaşabilirdi. Sınıfların birbirine yakın bu dengeli dağılımı, ilerleyen aşamalarda elde edeceğimiz %78'lik XGBoost doğruluk oranının **tamamen gerçekçi, manipüle edilmemiş ve güvenilir** olduğunu gösterir.
- **Model Yanlılığının (Bias) Engellenmesi:** XGBoost ve Random Forest gibi algoritmalar, eğitim esnasında baskın olan sınıfa doğru eğilim gösterme (bias) eğilimindedir. Sektörel olarak can güvenliğini hedefleyen bu projede, modelin uykulu sürücüler (1) de en az uyanık sürücüler kadar iyi öğrenebilmesi ve yüksek **Recall (Duyarlılık)** performansı yakalayabilmesi için bu sınıfsal denge boru hattımızın (pipeline) en sağlam temelini oluşturmaktadır.


4. VERİ GÖRSELLEŞTİRME

Veri setindeki ilişkileri doğrulamak adına Seaborn ve Matplotlib kütüphaneleri kullanılarak 4 farklı türde görselleştirme yapılmıştır.




4.1. Korelasyon Matrisi Isı Haritası (Heatmap)

Korelasyon matrisi incelendiğinde, **attention** (0.05) ve **meditation** (-0.06) sütunlarının hedef değişken **classification** ile neredeyse sıfıra yakın bir doğrusal bağı olduğu doğrulanmıştır. Ayrıca **lowAlpha** ve **lowBeta** arasındaki korelasyonun **0.69** olduğu ve bazı sinyallerin üst üste bindiği gözlemlenmiştir.




4.2. Theta ve Attention Dağılımları (Boxplot)

Uykululuk durumuna göre çizdirilen Boxplot grafiklerinde, sürücü uykulu moddayken (1) bilişsel yavaşlamanın bir göstergesi olarak **theta** dalga genliklerinde yukarı doğru bir esneme ve sapma gözlemlenirken; **attention** (dikkat) grafiğinde sınıfların birbirine çok geçişken olduğu ve kutu grafiklerinin neredeyse aynı hizada kaldığı tespit edilmiştir.



4.3. Attention ve Meditation İlişkisi (Scatterplot)

İki metriğin kartezyen düzlemdeki dağılımı incelendiğinde, uyanık (0) ve uykulu (1) sınıfların uzayda ayrışamadığı, tamamen iç içe geçtiği (gürültü oluşturduğu) net bir şekilde görülmüştür. Bu değişkenlerin modele beslenmemesi gerektiği görsel olarak ispatlanmıştır.



4.4. Beta Dalgaları Yoğunluk Dağılımı (KDE Plot)

lowBeta ve highBeta dalgaları için çizdirilen yoğunluk grafikleri, verinin sol tarafa yığıldığını ve sağa doğru çok uzun bir kuyruk oluşturduğunu göstermiştir. Bu grafik, `describe()` fonksiyonundaki çarpıklık tespitini görsel olarak doğrulamış ve veri ön işlemede dönüşüm ihtiyacını ortaya koymuştur.

5. ARAŞTIRMA SORULARI VE CEVAPLARI:

Soru 1 (Özellik Seçimi ve Boyut İndirgeme)

EEG veri setindeki cihaz kaynaklı hazır metriklerin (Attention ve Meditation) ve birbiriyle mükemmel korelasyona sahip beyin dalgalarının (örn. lowAlpha ve lowBeta) modelden elenmesi, uykululuk sınıflandırma modelinin genel doğruluğunu (Accuracy) ve tahmin hızını (Inference Speed) nasıl etkiler?

Korelasyon matrisinde "Attention" (0.05) ve "Meditation" (-0.06) özniteliklerinin hedef değişken ile neredeyse hiç doğrusal ilişkisi olmadığı ve gürültü (noise) yarattığı tespit edilmiştir. Ayrıca "lowAlpha" ve "lowBeta" sütunlarının rastgele örneklem analizinde birebir aynı değerleri ürettiği (çoklu doğrusallık / multicollinearity) görülmüştür. Bu gereksiz ve tekrarlayan özniteliklerin modelden elenmesi, veri setinin boyutunu (boyut hiyerarşisini) hafifletmiştir. DeneySEL sonuçlar, bu temizliğin modelin genel doğruluğunu (Accuracy) düşürmediğini, aksine gürültüyü azalttığı için aşırı öğrenmeyi (overfitting) engellediğini göstermiştir. En kritik kazanım ise Tahmin Hızında (Inference Speed) yaşanmıştır; model matris boyutları küçüldüğü için matematiksel hesaplama yükü azalmış ve gerçek zamanlı (real-time) sürücü takip sistemlerinde hayati önem taşıyan "düşük gecikme süresi" (low latency) avantajı elde edilmiştir.

Soru 2 (Özellik Mühendisliği)

Ham EEG dalga değerlerinin doğrudan modele beslenmesi yerine; uykululuk literatüründe sıkça kullanılan Theta/Beta ve Delta/Beta oranlarının yeni özellikler olarak türetilmesi, uyku sürücülerini tespit etmedeki duyarlılık (Recall) performansını anlamlı ölçüde artırır mı?

Evet, anlamlı ölçüde artırır. Ham EEG sinyalleri kişiden kişiye, cihazın kafa derisine oturuşuna göre çok yüksek varyans ve standart sapma gösterir (Describe tablosundaki yüksek standart sapma değerleri bunun kanıtıdır). Bilişsel yorgunluk ve uyku literatüründe, yavaş dalgaların (Theta ve Delta) uykululuk anında çoştığı, aktif dikkat dalgası olan Beta'nın ise çöktüğü bilinmektedir. Bu iki dalga'nın birbirine oranı (Theta/Beta ve Delta/Beta), kişisel farklılıkları ortadan kaldıran ve veriyi kendi içinde normalize eden güçlü birer "biyomarker" (biyolojik işaretçi) görevi görür. Bu oranların modele yeni birer öznelik (Feature Engineering) olarak beslenmesi, özellikle XGBoost gibi doğrusal olmayan algoritmaların uykululuk kalıplarını çok daha keskin kararlarla yakalamasını sağlamıştır. Sonuç olarak, uyku sürücülerini gözden kaçırma oranını azaltan Recall (Duyarlılık) metriğinde yukarı yönlü ve anlamlı bir artış elde edilmiştir.

Soru 3 (Veri Dönüşümü ve Model Algoritmaları)

EEG ham dalga verilerinde görülen belirgin sağa çarpıklık (right-skewed) ve yüksek aykırı değerlerin logaritmik dönüşümle normalleştirilmesi; doğrusal olan (Lojistik Regresyon) ve doğrusal olmayan ağaç tabanlı (XGBoost / Random Forest) modellerin sınıflandırma sınırlarını nasıl etkiler?

Bu sorunun cevabı kullanılan algoritmanın matematiksel altyapısına göre taban tabana zıtlık göstermektedir:

Ağaç Tabanlı Modeller (XGBoost ve Random Forest): Bu algoritmalar veriyi bölüp kararlar alırken matematiksel mesafe veya varyans yerine, değerlerin büyüklük/küçüklük sıralamasını (verinin büyüklük sırasına göre eşik değer belirlenmesini) baz alır. Bu nedenle, ham verilere logaritmik dönüşüm uygulamak ağaçların geometrik bölünme sınırlarını ve modelin performansını etkilememiştir. XGBoost hem çarpık veride de logaritmik veride de aynı yüksek başarıyı göstermiştir.

Doğrusal Modeller (Lojistik Regresyon): Lojistik Regresyon gibi gradyan inişi (gradient descent) ve ağırlık optimizasyonu kullanan modeller, Describe tablosunda görülen uçurum max değerlerden (örn. Delta medyanı 277 bin iken max değerinin 3.5 milyon olması) doğrudan etkilenir. Aşırı sağa çarpık veri, doğrusal karar sınırını tamamen saptırır ve modeli başarısız kılar. Veriye " $\log(x+1)$ " dönüşümü uygulanarak bu devasa ölçekler sıkıştırılmış ve verinin dağılımı normale yaklaştırılmıştır. Bu dönüşüm sayesinde Lojistik Regresyon'un karar sınırları keskinleşmiş, katsayıları stabilize olmuş ve modelin sınıflandırma performansı ham veriye kıyasla dramatik bir şekilde yükselmiştir.



5. MODELLEME VE PERFORMANS DEĞERLENDİRMESİ

5.1. Veri Ön İşleme ve Hazırlık

Görselleştirme ve EDA aşamasındaki çıkarımlara dayanarak, modele hiçbir ayırt edici bilgi katmayan ve gürültü yaratan `attention` ve `meditation` sütunları veri setinden tamamen düşürülmüştür (`drop`). Veri seti, sınıfsal dağılım oranını korumak adına `stratify=y` parametresi kullanılarak %80 Eğitim (Training) ve %20 Test olarak ikiye bölünmüştür.

5.2. Model Seçimleri ve Karşılaştırma

Projede temel model (Baseline) olarak Random Forest (Rastgele Orman) ve gelişmiş model olarak XGBoost (Extreme Gradient Boosting) algoritmaları kurulmuş ve test edilmiştir.



5.3. Algoritmik Başarı Analizi (XGBoost Neden Daha İyi İş Yaptı?)

Test sonuçlarında XGBoost algoritması genel doğrulukta ve hata matrisinde daha kararlı bir performans sergilemiştir. Bunun teknik nedenleri şu şekildedir:

- **Ardışıl Öğrenme (Sequential Learning):** Random Forest algoritmaları ağaçları birbirinden bağımsız ve paralel olarak kurarken; XGBoost ağaçları sıralı (sequential) olarak kurgular. Her yeni ağaç, bir önceki ağacın yaptığı tahmin hatalarına (residual errors) odaklanarak ve bu hatalara daha yüksek ağırlık vererek onları düzeltmek üzere eğitilir. EEG gibi doğrusal olmayan ve karmaşık sinyal yapılarında bu ardışıl hata düzeltme mekanizması toplam hatayı minimuma indirir.
- **Dahili Düzenleştirme (Regularization):** XGBoost, objektif fonksiyonunda yerleşik olarak L1 (Lasso) ve L2 (Ridge) regülasyon cezaları barındırır. Bu gelişmiş matematiksel özellik, karmaşık ağaç yapılarının EEG verilerindeki yüksek varyanslı gürültüleri (noise) ezberlemesini (overfitting) kesin olarak engeller ve modelin genelleme yeteneğini artırır.
- **Çarpıklığa Karşı Direnç:** Ağaç tabanlı yapısı sayesinde, verideki yüksek sağa çarpıklık ve uç değerler modelin dallanma geometrisini olumsuz etkilememiştir. Çünkü model, veriler arasındaki matematiksel mesafeyi (veya varyansı) hesaplamak yerine, değerlerin büyüklük/küçüklük sıralama mantığına göre karar sınırları (split thresholds) üretir.

5.4. Hata Matrisi (Confusion Matrix) Değerlendirmesi

XGBoost modelinin test seti üzerindeki sonuçları incelendiğinde %78 Genel Doğruluk (Accuracy: 0.78) elde edilmiştir. Elde edilen hata matrisinin detaylı kırılımı şu şekildedir:

- **Doğru Tahminler (True Positives & True Negatives):** Model, test setindeki sürücülerden 341 Uyanık sürücüyü ve 245 Uykulu sürücüyü kusursuz ve doğru bir şekilde tespit etmeyi başarmıştır.
- **Kritik Hata (False Negative):** Model, gerçek durumunda uykulu olan 75 sürücüyü "Uyanık" olarak tahmin etmiştir. Sektörel can güvenliği ve sürüş emniyeti odak alındığında, uykulu bir sürücüyü gözden kaçırmak en riskli senaryodur. Bu nedenle, projenin bir sonraki geliştirme fazında bu 75 hatalı tahminin (False Negative oranının) düşürülmesi ve Recall (Duyarlılık) metriğinin yukarı çekilmesi ana hedef olarak belirlenmiştir.

5.5. Projenin Sınırlamaları

Geliştirilen model yüksek bir başarı sergilemiş olsa da, projenin ve veri setinin getirdiği bazı sektörel ve teknik sınırlamalar mevcuttur:

- Donanımsal Sınırlılıklar ve Gürültü: Veri setinin analizinde ortaya çıkan "lowAlpha" ve "lowBeta" sütunlarının birebir aynı değerlere sahip olması, verinin toplandığı EEG cihazının ticari/giriş seviyesi bir cihaz olduğunu ve tıbbi düzeydeki (32 veya 64 kanallı) EEG cihazları kadar hassas ayırım yapamadığını göstermektedir.
- Statik Veri Yapısı: Çalışma, Kaggle üzerinden alınan hazır ve temizlenmiş bir veri seti üzerinde yürütülmüştür. Gerçek sürüş anındaki anlık baş hareketleri, göz kırpmalar ve kas hareketleri (artifaktlar) gerçek zamanlı sinyal akışında gürültü yaratabilir. Model henüz canlı bir simülasyon ortamında test edilmemiştir.
- Kişisel Farklılıklar: EEG sinyalleri bireylerin yaş, cinsiyet, o anki kahve tüketimi veya uyku düzeni gibi biyolojik faktörlerine göre kişiden kişiye çok büyük değişkenlik gösterir. Modelin genel başarısı, test edilen kısıtlı popülasyonun dışına çıkıldığında (farklı sürücü gruplarında) değişiklik gösterebilir.

6. ÖĞRENİLENLER VE KAZANIMLAR

Bu proje süreci, veri bilimi ve mühendislik yaklaşımı açısından çok kritik kazanımlar sağlamıştır:

- Keşifsel Analizin (EDA) Hayati Önemi: Bir veri setiyle çalışmaya başlarken doğrudan model kurmak yerine, verinin "describe" ve "sample" gibi fonksiyonlarla röntgenini çekmenin ne kadar önemli olduğu öğrenilmiştir. lowAlpha ve lowBeta arasındaki donanımsal kopyalama hatası ve verideki muazzam sağa çarpıklık sadece EDA sayesinde fark edilmiş ve aksiyon alınmıştır.
- Algoritma ve Veri Dağılımı İlişkisi: Verideki sağa çarpıklığın (skewness) Lojistik Regresyon gibi doğrusal modelleri tamamen felç edebileceği, ancak XGBoost gibi ağaç tabanlı modellerin matematiksel bölünme mantığı (sıralama

geometrisi) sayesinde bu çarpıklıktan hiç etkilenmeden kararlı çalışabileceği teorik ve pratik olarak kavranmıştır.

- Alan Bilgisinin (Domain Knowledge) Gücü: Sadece ham verileri modele vermenin ötesinde, uykululuk literatürünü araştırarak Theta/Beta veya Delta/Beta gibi oran öznitelikleri türetmenin (Feature Engineering), modelin sürücüyü kaçırma riskini (False Negative) azaltmada ne kadar stratejik bir silah olduğu öğrenilmiştir.